Kinvecta

LA CAPA DE MEMORIA · PARTE 1

Por qué tu IA necesita un cerebro

El modelo olvida en cada sesión. Dale una memoria propia: archivos simples, enlazados y legibles por cualquier IA.



Video de 18 minutos

Todos los roles

Cualquier arnés · cualquier modelo

ISABELLA

Kinvecta

HOY

Al terminar, tus participantes podrán…

1

Explicar por qué un modelo olvida y dónde puede vivir la memoria

2

Describir el patrón LLM Wiki: raw, wiki, índice, registro y el esquema

3

Recorrer una bóveda: capas de memoria, el latido y la escalera de recuperación

4

Conectar cualquier IA a un cerebro y obtener respuestas con citas

CAPÍTULOS · VIDEO DE 18 MIN

a escala



ANTONIO

Kinvecta

POR QUÉ IMPORTA

Tu IA es brillante y no tiene memoria

01

Cada sesión empieza vacía

La ventana de contexto es la memoria de trabajo. Cierras el chat y desaparece.

02

La memoria integrada no es tuya

La memoria del proveedor vive en un solo producto. No puedes leerla, auditarla ni llevártela.

03

El conocimiento está disperso

Guías, transcripciones y decisiones viven en carpetas que nadie vuelve a leer, así que la IA tampoco.

La pregunta de hoy: **¿Cómo le damos a cualquier IA una memoria propia y que podamos verificar?**

Kinvecta

BLOQUE 1 · POR QUÉ OLVIDA LA IA

El modelo olvida. Los archivos, no.

> La memoria no es una función del modelo que debas esperar. Son archivos que tú controlas.

Contexto = memoria de trabajo

Un presupuesto fijo de tokens que se vacía al terminar la sesión

Sin archivos, no hay recuerdo

Pregúntale por la semana pasada y solo adivina o dice que no sabe

Archivos = memoria que perdura

Carga los pocos archivos correctos al inicio y la respuesta vuelve, con fuente



ANTONIO

Kinvecta

BLOQUE 1 · CÓMO RECUERDA UN CEREBRO

Tu propio cerebro ya resolvió esto

FIG. 2 CÓMO RECUERDA UN CEREBRO

PASO 03 / 03 · RECORDAR

ENTRA EXPERIENCIA

nota

decisión

transcripción



ENTRA PREGUNTA

pista:
¿qué decidimos?

✓ partes de 90 min

SUEÑO · REPASO

hipocampo -> corteza

> codifica rápido. repasa para guardar. recuerda por pista.

Hipocampo
→ memoria de trabajo (rápida)

Repaso al dormir
→ el latido programado

Neocorteza
→ páginas wiki (duraderas)

Recuerdo por pista
→ una consulta con citas

ANTONIO

Kinvecta

BLOQUE 1 · TRES HOGARES PARA LA MEMORIA

¿Dónde puede vivir la memoria de una IA?

Memoria integrada del producto

Puedes leerla	EN PARTE
Sirve en cualquier app	NO
Muestra gráficos	NO
Configuración	NINGUNA

Ideal para preferencias personales dentro de una app.

Base de datos vectorial (RAG)

Puedes leerla	NO
Sirve en cualquier app	CON CÓDIGO
Muestra gráficos	NO
Configuración	PIPELINE

Ideal para millones de documentos y búsqueda a escala.

Markdown + vistas HTML

Puedes leerla	SÍ
Sirve en cualquier app	SÍ
Muestra gráficos	VÍA HTML
Configuración	UNA CARPETA

Ideal para el conocimiento valioso de una persona o un equipo.

NUEVO · MAY 2026

Para lo que las personas **leen**, genera **HTML** (diagramas, tablas, pestañas). Para lo que la IA **recuerda**, usa **markdown**.

Kinvecta

BLOQUE 2 · EL PATRÓN LLM WIKI

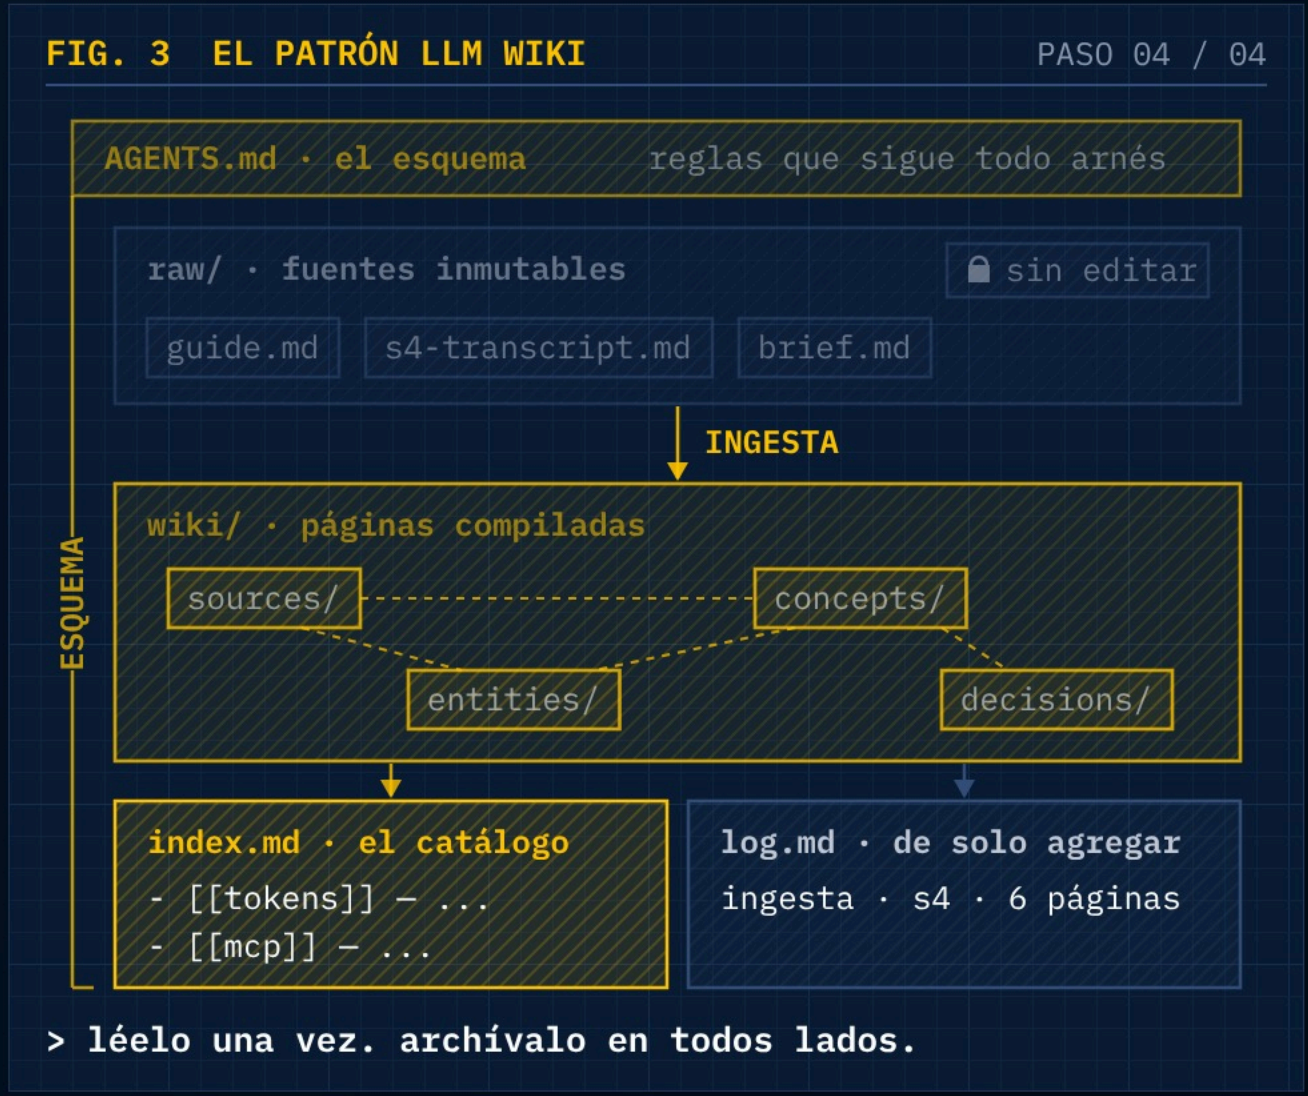
Léelo una vez, archívalo en todos lados

> Las fuentes entran una vez. La IA reparte lo que enseñan en páginas enlazadas.

raw/ guarda las fuentes
Guías, transcripciones, artículos recortados. La IA los lee y nunca los edita

wiki/ guarda las páginas
Fuentes, conceptos, entidades y decisiones que la IA escribe y enlaza

index.md, log.md, AGENTS.md
El catálogo, el registro de auditoría y las reglas que sigue todo arnés



Kinvecta

BLOQUE 2 · TRES OPERACIONES

El conocimiento se acumula

> Cada buena respuesta se guarda, así que la próxima vez basta una lectura.

Ingesta

Una fuente actualiza de 3 a 10 páginas, el índice y el registro

Consulta

Índice primero, pocas páginas, respuesta con [[citas]]; las buenas se guardan como páginas

Lint

Enlaces rotos, huérfanas, datos obsoletos y contradicciones, detectados y corregidos



ANTONIO

Kinvecta

RECORRIDO

Mira cómo una fuente se reparte por el cerebro

Mira

1	**Suelta una fuente**	Pon un documento nuevo en inbox/ y pide: “incorpora esto”.
2	**Mira cómo se reparte**	Una página de fuente, varias páginas de conceptos actualizadas, index.md y log.md con cambios.
3	**Pregunta entre fuentes**	“¿Cómo se relacionan los tokens con la escalera de recuperación?” La respuesta cita páginas de dos sesiones.
4	**Revisa el cambio**	git diff muestra cada edición. Nada queda escondido dentro de un modelo.

BLOQUE 3 · DENTRO DE LA BÓVEDA

Cuatro capas de memoria

> Solo las capas pequeñas de arriba cuestan tokens en cada sesión.

Central y trabajo: siempre cargadas

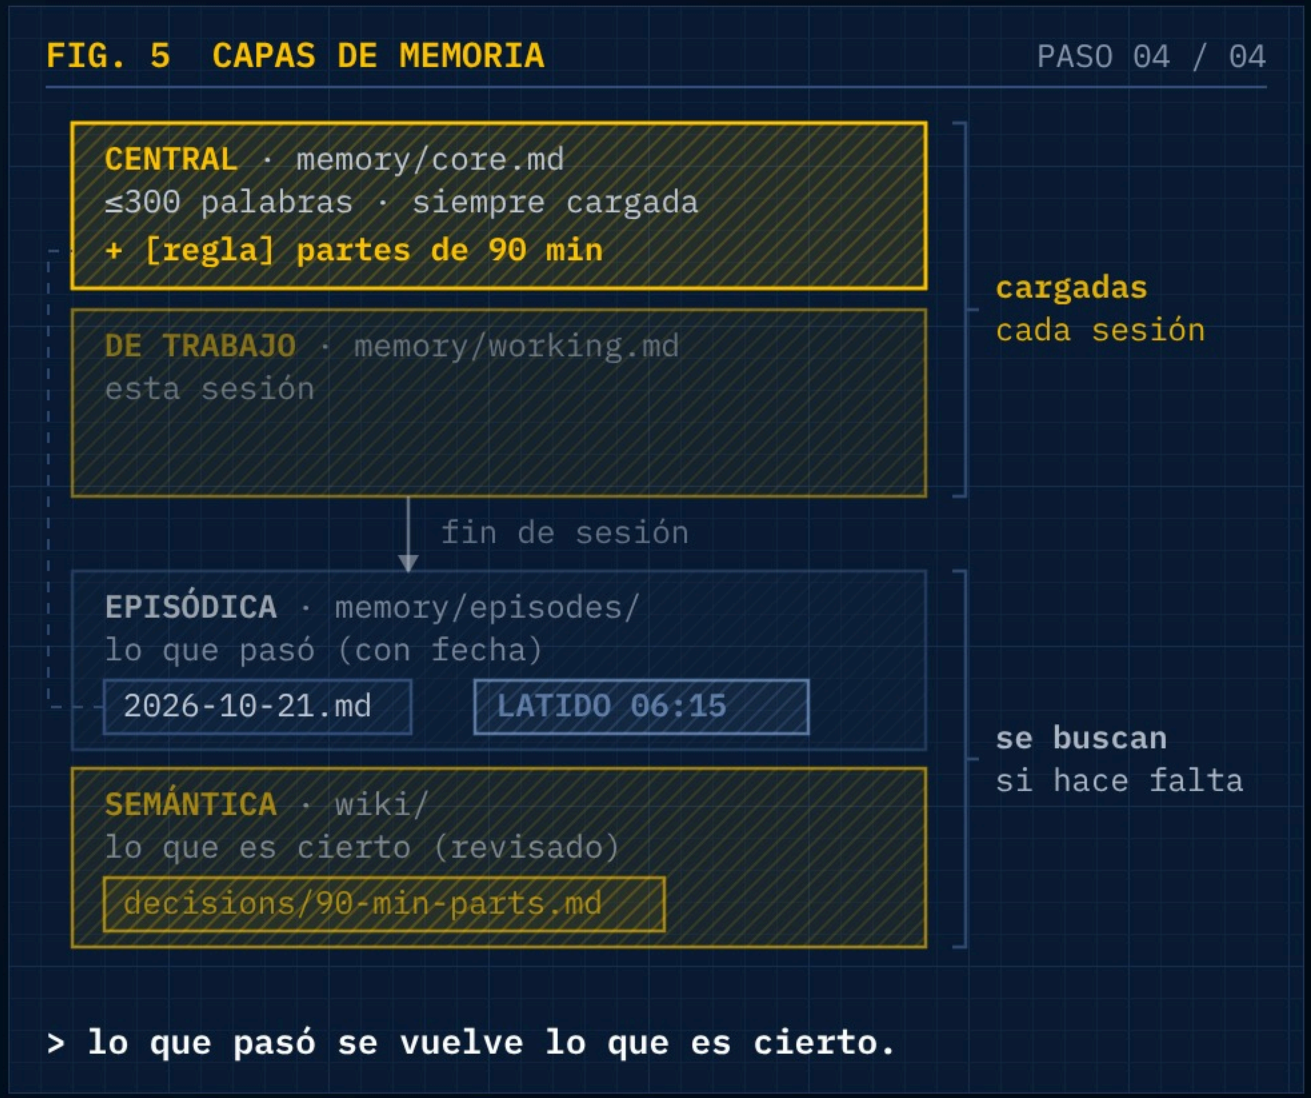
Unos cientos de palabras de datos fijos, más las notas de esta sesión

Episódica: lo que pasó

Archivos fechados con las notas de trabajo de cada sesión

Semántica: lo que es cierto

Páginas wiki revisadas; el latido programado promueve hechos a ellas



BLOQUE 3 · EL LATIDO

El cerebro se ordena mientras duermes

> Un comando programado mantiene limpio el cerebro, sin que nadie tenga que acordarse.

Una tarea programada

Corre sola, a diario o cada semana, cuando nadie trabaja en la bóveda

Archivar, reindexar, lint

Archiva las notas, actualiza la búsqueda, escribe un reporte de salud

Reflexión (opcional)

Una herramienta de IA promueve hechos a la wiki y a core.md, y marca el resto

FIG. 6 EL LATIDO

LATIDO 04 / 04

06:15 · diario, sin supervisión



01 ARCHIVAR	working.md -> episodes/	✓
02 REINDEXAR	palabras clave + embeddings	✓
03 LINT	reporte -> memory/reports/	✓
04 REFLEXIÓN	hechos -> wiki + core.md	✓

(opcional: una IA corre la skill de reflexión)

> mientras duermes, el cerebro se ordena.

BLOQUE 3 · ESCALERA DE RECUPERACIÓN

Primero, la recuperación barata

> Cada peldaño cuesta más tokens. Detente cuando tengas suficiente.

core.md, luego el índice

Casi todo se resuelve en el peldaño 2: lee resúmenes, abre una página

Busca si el índice no basta

Palabras clave más búsqueda semántica local; luego sigue los enlaces

raw/ solo para el texto exacto

La factura de tokens más alta; abre una fuente solo para citarla



Kinvecta

BLOQUE 3 · PORTABILIDAD

Un cerebro, cualquier arnés

> El modelo se renta. El cerebro es tuyo.

AGENTS.md es el manual

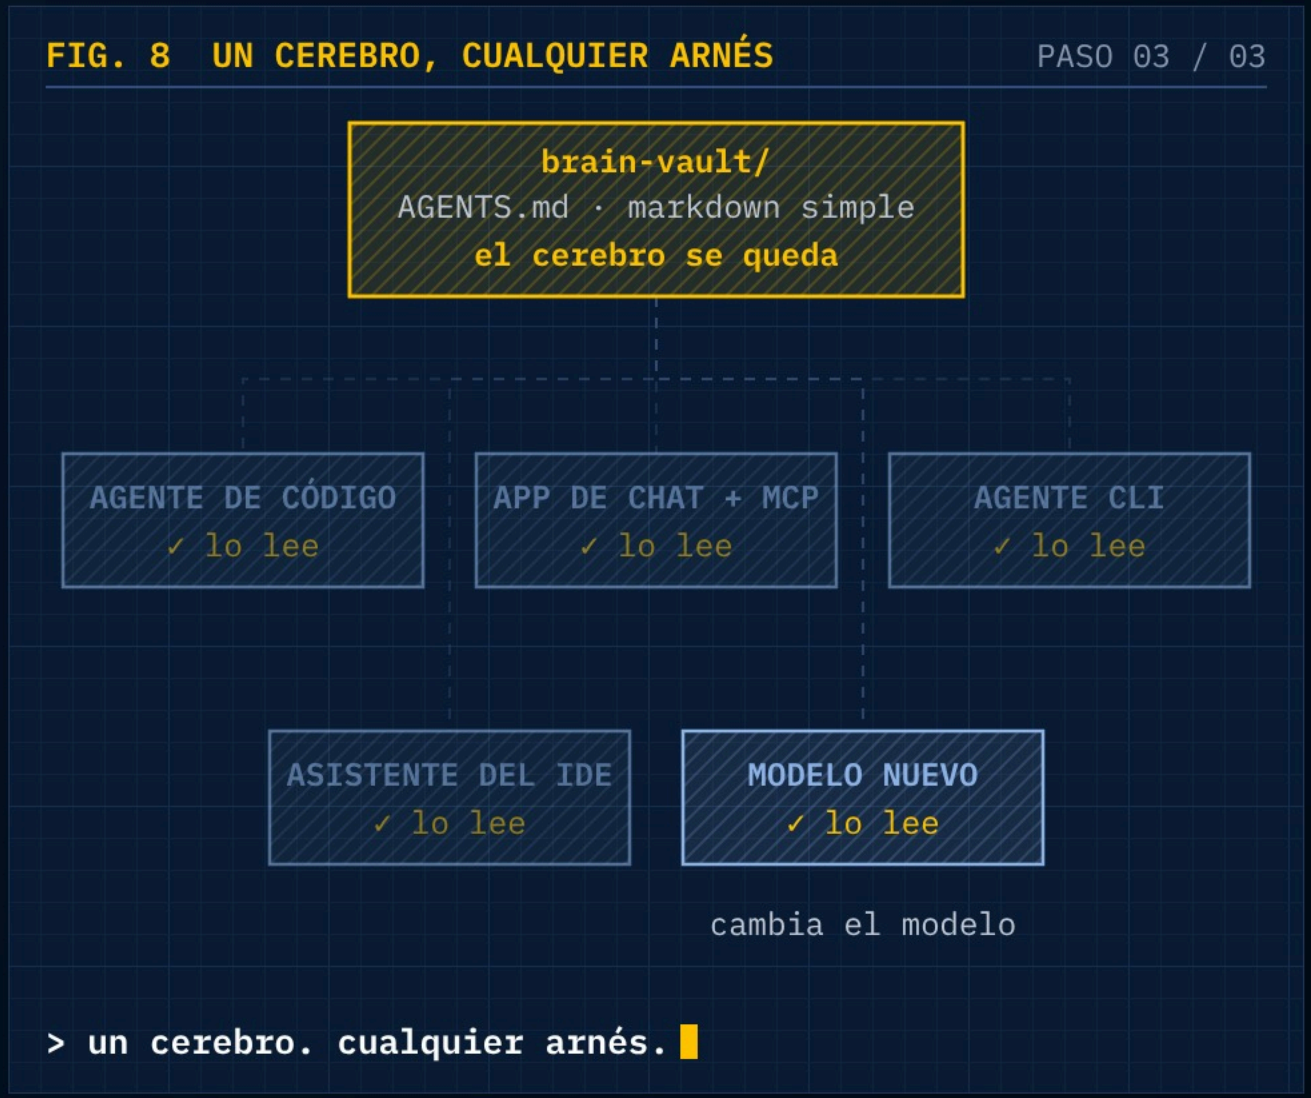
Mapa de carpetas, reglas, escalera de recuperación y seguridad, en un archivo

Cada herramienta lo halla a su modo

Casi todas leen AGENTS.md; otras lo importan desde su archivo de instrucciones

Cambia de modelo, no de cerebro

La resiliencia de la Sesión 2, aplicada al conocimiento



Kinvecta

LA REGLA DE ORO

La memoria vive en **archivos**, no en el modelo. Lee primero el **índice**. Las fuentes crudas, al final. Cada respuesta **cita** una página.

Si no puedes abrir la página de donde salió, no es memoria. Es una suposición.

ANTONIO

Kinvecta

LABORATORIO PRÁCTICO 1

Las mismas preguntas, con y sin cerebro

Pausa y practica

A	**Línea base**	En cualquier herramienta de IA sin archivos adjuntos, haz las tres preguntas del laboratorio. Anota qué responde.
B	**Con el cerebro**	Abre la herramienta dentro de brain-vault/. Haz las mismas tres. Abre cada [[cita]] que te dé.
C	**Aliméntalo**	Pon la nota del laboratorio en inbox/, pide la ingesta y repite la pregunta 3. Lee log.md.
D	**Repaso del laboratorio**	¿Qué respuestas cambiaron? ¿Qué citas se sostuvieron? ¿Qué te ahorró el índice?

ANTONIO

Kinvecta

PON A PRUEBA LO APRENDIDO

¿Todo el grupo puede responder esto?

1

¿Por qué una ventana de contexto más grande no le da memoria a un modelo?

2

Menciona una ventaja y un límite de una base de datos vectorial frente a un cerebro en markdown.

3

¿Qué guarda cada uno: raw/, wiki/, index.md y log.md?

4

¿Qué hace el latido durante la noche y qué nunca va a tocar?

5

Una pregunta se puede responder desde index.md. ¿Por qué no buscar en raw/ de todos modos?

6

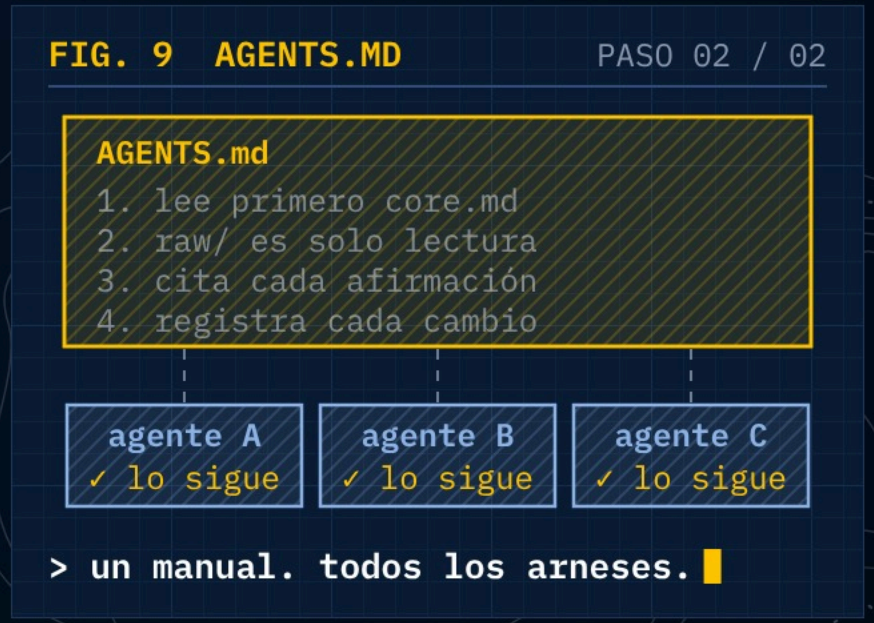
Cambias a otra herramienta de IA. ¿Qué tiene que cambiar en el cerebro?

ANTONIO

Kinvecta

SIGUIENTE: PARTE 2 · EL MANUAL DE OPERACIÓN

¿Qué hace que toda IA actúe igual en tu cerebro?



Lo que cubre la Parte 2

- AGENTS.md, el esquema
- Reglas y plantillas de página
- Skills para cada operación
- Un cerebro, todos los arneses

ISABELLA

Kinvecta

LA CAPA DE MEMORIA · PARTE 1 · CIERRE

Memoria propia, para cualquier IA

FIG. 10 EL CEREBRO QUE CONSTRUISTE

PÁGINAS WIKI 55 / 55

+ guía
+ 10 transcripciones
+ 3 informes



core.md · siempre cargado
index.md · se lee primero
wiki/ · 55 págs. enlazadas

> memoria propia. cualquier IA, cada sesión.

El cerebro de referencia de hoy: **14 fuentes** compiladas en **55 páginas enlazadas**, legibles por cualquier herramienta de IA.

ISABELLA