Kinvecta

LA CAPA DE MEMORIA · PARTE 4

Recuperación a escala

Búsqueda por palabras clave, por significado e híbrida para un cerebro que ya rebasó su índice. Medida, no adivinada.



Video de 12 minutos

Todos los roles

Corre en tu computadora

ANTONIO

Kinvecta

HOY

Al terminar, tus participantes podrán…

1

Explicar cuándo index.md ya no basta y por qué cargarlo todo falla

2

Comparar palabras (BM25) y significado (embeddings): cuándo gana cada uno

3

Correr búsqueda híbrida con fusión de rankings en fragmentos por encabezado y sellados

4

Medir la recuperación con una pequeña clave de respuestas y corregir una falla

CAPÍTULOS · VIDEO DE 12 MIN

a escala del video

0:00	1:06	3:05	5:42	7:06	9:38	10:42
Intro	Escala	Palabras · sentido	Híbrida	Medir	Laboratorio 4	Cierre

ISABELLA ·····

Kinvecta

BLOQUE 1 · POR QUÉ IMPORTA

Con cientos de páginas, busca.

ANALOGÍA

> Una tiendita vs. una bodega: en una puedes revisar cada estante; en la otra, no.

index.md funciona en pequeño

Unas 100 fuentes, cientos de páginas (Karpathy)

Luego es demasiado largo

Las entradas largas entierran el medio y gastan tokens

La búsqueda trae lo que importa

brain search ordena páginas; lee solo esas



ANTONIO

Kinvecta

BLOQUE 1 · LO QUE DICE LA INVESTIGACIÓN

Más contexto no es mejor recuperación

53.8%

Respuesta enterrada a la mitad

Por debajo del 56.1% que el modelo logró sin ningún documento. Lost in the Middle, GPT-3.5

18/18

Modelos empeoraron

Todos los modelos probados empeoraron al crecer la entrada, aun en tareas simples. Chroma, 2025

−49%

Recuperaciones fallidas

Embeddings contextuales más búsqueda por palabras; −67% con un reranker. Anthropic, 2024

+18%

Híbrida vs. palabras

Fusionar los rankings de palabras y significado superó a BM25 solo en nDCG@10. Elastic (ELSER), 2023

Recupera las **pocas páginas que importan**. Combina **palabras** y **significado**. Con menos de unos 200k tokens, cárgalo todo.

ANTONIO

Kinvecta

BLOQUE 2 · BÚSQUEDA POR PALABRAS

Por palabras: las raras pesan más

ANALOGÍA

> El índice al final de un libro: buscas “ORA-01017” y te manda a la página 212.

Los términos raros pesan más

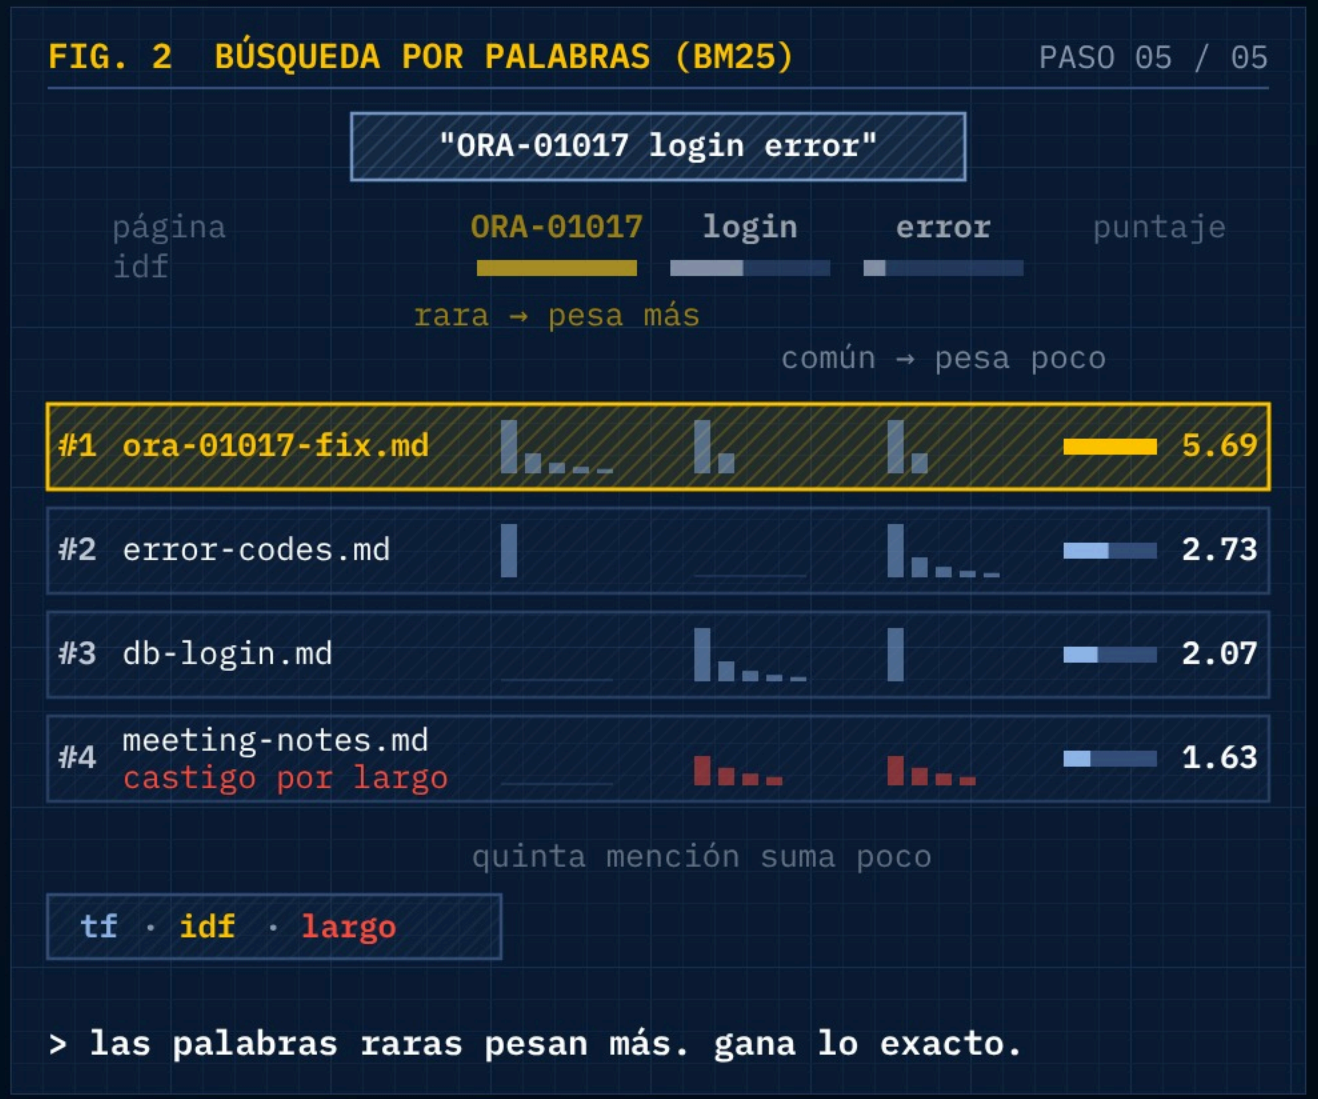
Un código de error gana a una palabra como “error” (IDF)

Repetir ayuda, cada vez menos

La quinta mención suma poco (k1)

Las páginas largas no hacen trampa

Normalización por largo (b = 0.75)



ANTONIO

Kinvecta

BLOQUE 2 · BÚSQUEDA POR SIGNIFICADO

Busca por significado, no por palabras

ANALOGÍA

> Una bibliotecaria que entiende el sentido: le pides “arreglar mi carro” y trae la carpeta de vehículos.

El texto se vuelve 768 números

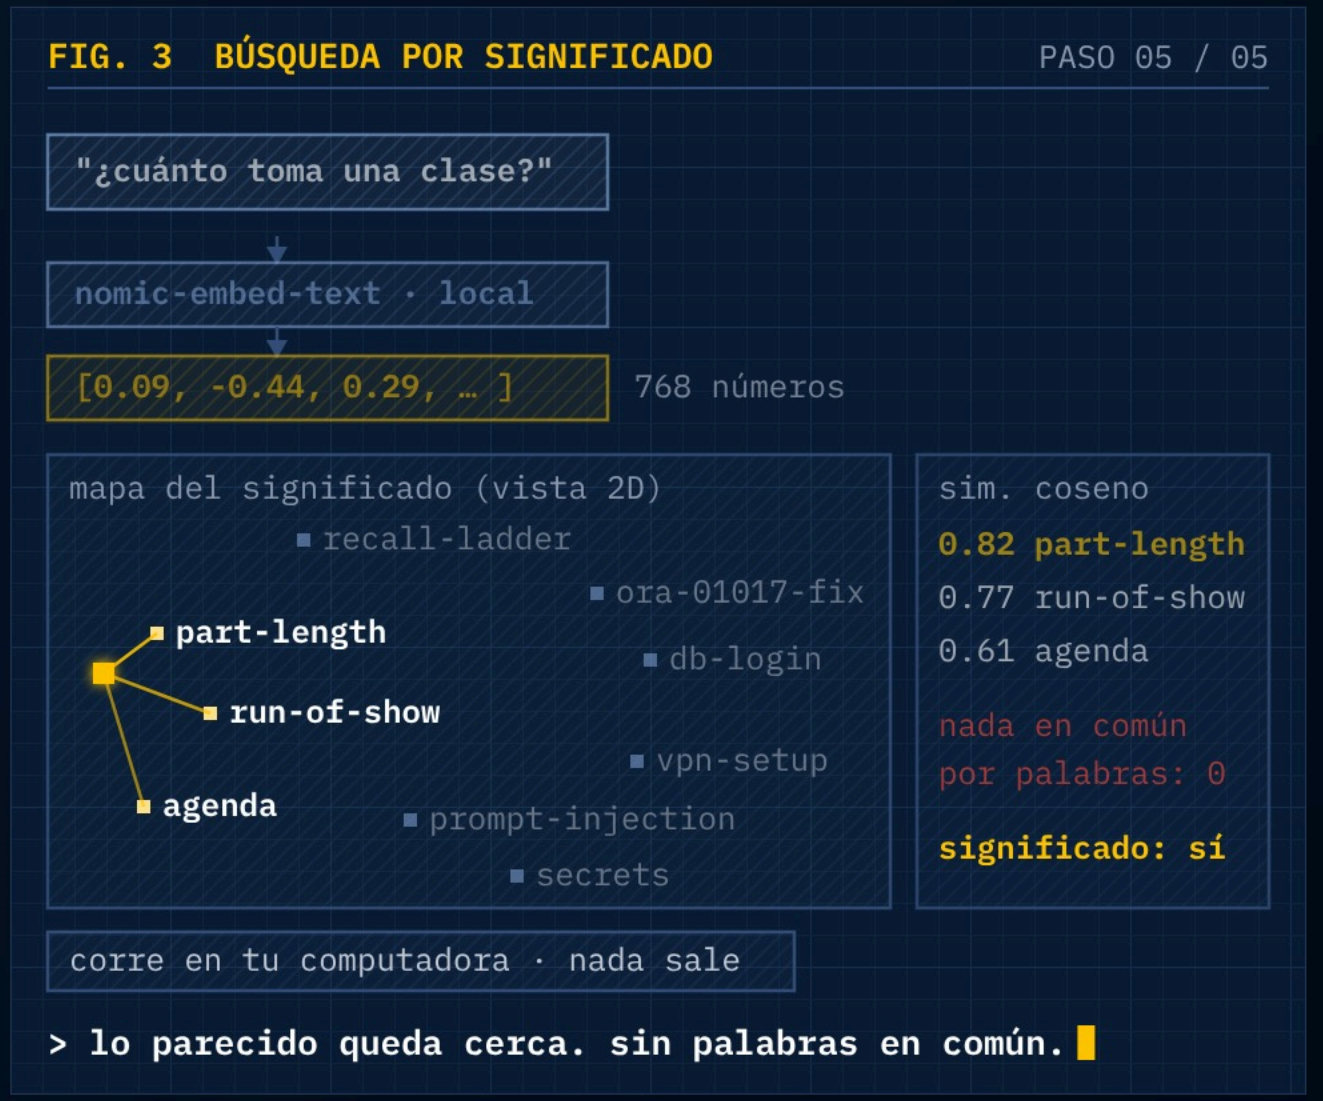
Significados parecidos quedan cerca

Encuentra paráfrasis

Sin necesidad de palabras en común

Débil con tokens exactos

Códigos, IDs, números y el “no”



Kinvecta

BLOQUE 2 · EMBEDDINGS LOCALES

El significado se queda en tu computadora

> brain index calcula el embedding de cada fragmento una vez y solo recalcula los archivos que cambiaron.

nomic-embed-text con Ollama

137M parámetros, 768 dims, 274 MB, Apache-2.0

Nada sale de la laptop

Notas y vectores se quedan en .brain/index.sqlite

¿Sin Ollama? Igual funciona

brain search pasa a búsqueda por palabras



ISABELLA

BLOQUE 3 · BÚSQUEDA HÍBRIDA

Híbrida: dos jueces, un ranking

FIG. 5 DOS JUECES, UN RANKING — PASO 04 / 04



> el acuerdo sube. sin igualar escalas de

ANALOGÍA Escalas distintas, así que no promedies: premia lo que **ambos** ponen arriba. Cada lista suma **1 / (60 + posición)**.

BLOQUE 3 · FRAGMENTACIÓN

Corta en encabezados. Sella cada tarjeta.

ANALOGÍA

> Tarjetas de recetas con buen título y apodos: un platillo por tarjeta, fácil de encontrar.

Fragmentos por encabezado

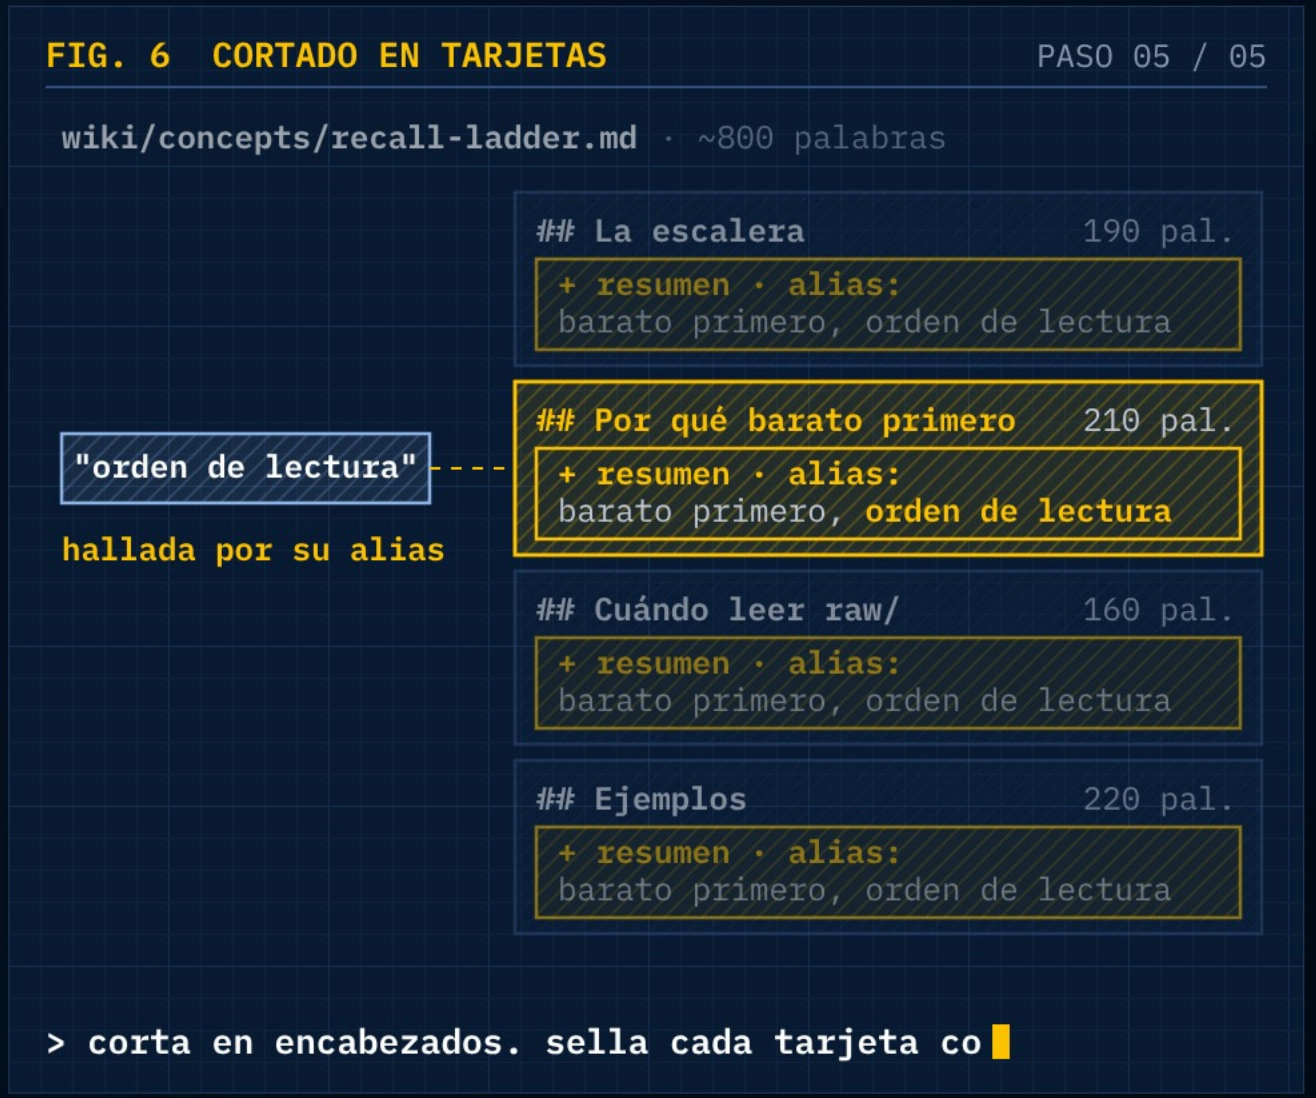
Hasta 220 palabras de texto (≈290 tokens), cortados en los encabezados

Sella cada fragmento

El resumen y los alias de la nota viajan con él

Los alias atrapan apodos

Agrega las palabras que tu equipo de verdad usa



BLOQUE 4 · MIDE LA RECUPERACIÓN

Mide la recuperación antes de ajustar

ANALOGÍA

> Un examen con clave de respuestas: repite el mismo examen tras cada cambio.

Un conjunto de referencia

20–50 preguntas reales, cada una con su página correcta

recall@5 y MRR

¿Apareció? ¿Qué tan arriba?

Repítelo tras cada cambio

Alias, fragmentación, k1 y b, o un modelo nuevo

FIG. 7 UN EXAMEN CON CLAVE DE RESPUESTAS — PASO 05 / 05

bóveda de referencia · 6 preguntas · posición de la correcta

pregunta → página esperada	PALABRAS	SIGNIFICADO	HÍBRIDA
streamable HTTP vs stdio → mcp-transports…	1	1	1
cosign → image-signing…	1	1	1
stop a web page hijack… → prompt-injection	2	4	1
why does it forget… → agent-memory-layers	5	2	3
which model if the vend… → ai-resilience	4	1	1
crawl walk run → five-stage-training…	1	3	1
recall@5	6/6	6/6	6/6
MRR	0.66	0.68	0.89

+ alias: crawl walk run

MRR = promedio de 1/posición

> mide antes y después de cada cambio.

Kinvecta

BLOQUE 4 · QUÉ PUEDE FALLAR

Tres formas en que la búsqueda falla en silencio

UNILATERAL

La híbrida entierra un acierto solitario

Una página que solo un juez encuentra puede quedar debajo de páginas que a ambos les gustan a medias. Revisa cada modo.

DESACTUALIZADO

El índice está desactualizado

La búsqueda lee .brain/index.sqlite. Corre brain index después de editar o hacer una ingesta.

CAMBIADO

Modelo nuevo, vectores viejos

Los vectores de modelos distintos no se mezclan. ¿Modelo nuevo? Reindexa antes de buscar.

Las barreras de seguridad: **conjunto de referencia · reindexar · revisar cada modo · recalcular embeddings**

Kinvecta

RECORRIDO

La misma pregunta, tres búsquedas

Mira

1	**Indexa la bóveda**	brain index --no-embed, luego brain index con Ollama corriendo.
2	**Tres modos**	brain search "cosign" --mode keyword | semantic | hybrid
3	**Una paráfrasis**	“why does the assistant forget everything between chats?” (¿por qué el asistente lo olvida todo entre chats?)
4	**Corrige una falla**	Alias “crawl walk run”, brain index y repite el examen.

Kinvecta

LA REGLA DE ORO

Palabras para lo **exacto**. Significado para las ideas. Fusiona los **rankings**. Mide cada **cambio**.

Cuando la búsqueda no encuentra una página, corrige la página: su resumen y sus alias.
Luego repite el examen.

ANTONIO

Kinvecta

LABORATORIO PRÁCTICO 4

Indexa, califica, corrige.

Pausa y practica

A	**Indexa**	brain index --no-embed, luego con Ollama. Revisa brain stats.
B	**Califica**	python3 run_eval.py con golden.csv. Anota las posiciones en 3 modos.
C	**Explica**	Elige una fila donde los modos no coincidan. ¿Por qué?
D	**Corrige**	Alias “crawl walk run”, brain index y califica otra vez.
E	**Amplía**	Agrega a golden.csv una pregunta real tuya.

Kinvecta

PON A PRUEBA LO APRENDIDO

¿Todas las personas pueden responder esto?

1

¿Por qué index.md no basta con cientos de páginas? Menciona un resultado de investigación.

2

¿Qué tres cosas premia o castiga BM25?

3

Da una consulta donde las palabras le ganan al significado, y una donde gana el significado.

4

¿Cómo fusiona RRF dos listas, y por qué usa posiciones en vez de puntajes?

5

¿Por qué sellar cada fragmento con el resumen y los alias de su nota?

6

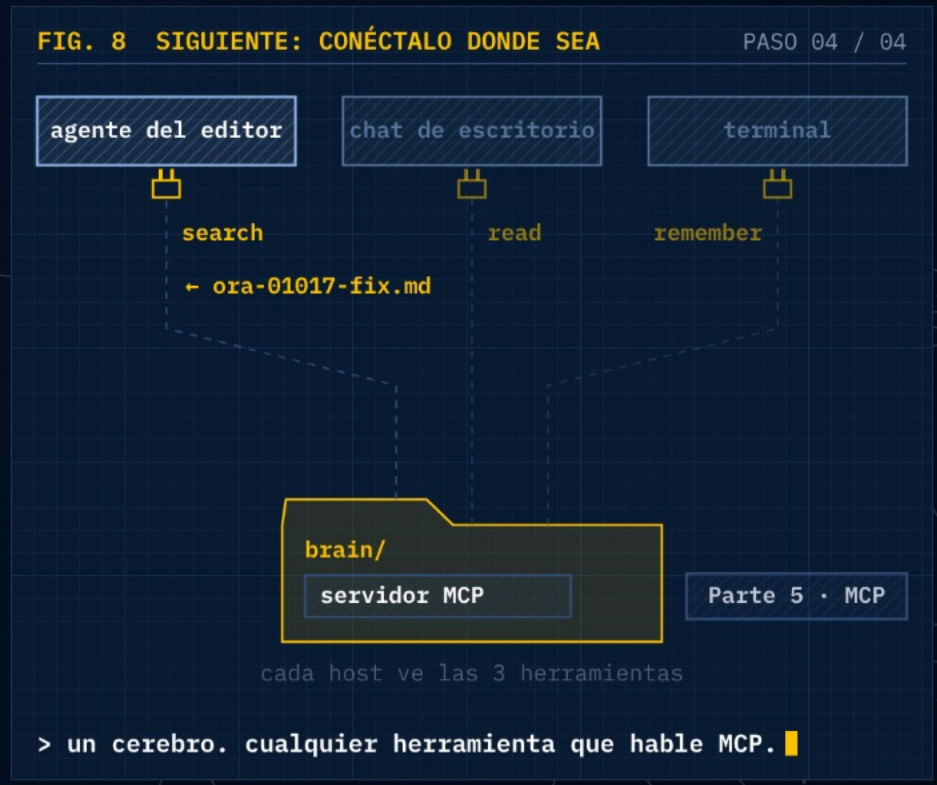
¿Qué te dicen recall@5 y MRR, y cuándo los vuelves a correr?

ISABELLA

Kinvecta

SIGUIENTE: PARTE 5 · CONÉCTALO DONDE SEA

Un cerebro, cada herramienta con MCP



Qué cubre la Parte 5

- El servidor MCP del cerebro
- stdio vs. Streamable HTTP
- Límites de escritura
- La CLI de Obsidian

ANTONIO